

Natalia Rodríguez Franco – 202610492

Alejandro Chica Cardona – 202613881

Emiliano Quintero Mogollon – 202614883

Juan Caballero Moreno – 202614461

Link del repositorio: https://github.com/nataliarf23/Proyecto1_DATA.git

1. Entendimiento del Problema

1.1. Comprensión del problema:

- Who: Población adulta (Mayor de 18 años) residentes de la ciudad de Bogotá en los últimos 12 meses y la alcaldía de Bogotá.
- What: Relación de las características de las personas, como su edad, sexo y estado civil, con su bienestar general, que incluye aspectos como la satisfacción con la vida, salud, ingresos, la seguridad, el trabajo y el tiempo libre.
- Where: Bogotá.
- When: Últimos 12 meses.
- Why: Utilizar los datos disponibles para identificar características, diferencias y patrones que puedan aportar elementos para comprender mejor la situación de la población estudiada.

1.2. Objetivo de negocio: La Alcaldía de Bogotá busca identificar la relación existente entre características de las personas, como su edad, sexo y estado civil, en su bienestar general.

1.3. Pregunta cuantitativa: ¿Cómo varía el nivel de satisfacción con la salud entre los diferentes grupos de edades de la población adulta de Bogotá?

1.4. Antes de consultar la base de datos, se requeriría la siguiente información:

- Variable geográfica que mencione la residencia, para poder filtrar únicamente por Bogotá
- Variable de edad, para filtrar únicamente a la población mayor de edad, y dividir la población por grupos de edades (Variable numérica discreta). O bien una variable que clasifique por grupos de edades.

- Una variable de percepción o de nivel de satisfacción con el estado de salud (Una variable ordinal)

2. Preparación de los Datos

2.1. Variables seleccionadas:

Variable	¿Qué representa?	Tipo de dato
P6040	Edad del encuestado	Numérico Discreto
P1897	Nivel de satisfacción con su salud actual	Categorico Ordinal

Observación: Al explorar las variables disponibles para identificar la residencia en Bogotá durante los últimos 12 meses, se encontró que la única variable relacionada (P753S2) corresponde a una pregunta que solo aplica a personas que reportaron un cambio de municipio de residencia, por lo que su uso como filtro reduce la muestra a tan solo 253 registros. Ante esta limitación, se decidió realizar el análisis sin aplicar el filtro geográfico de residencia en Bogotá, considerando únicamente el filtro de edad.

2.2. Filtrado de datos: Al aplicar el filtro de edad se identificó que la muestra que representa a la población con 18 años o más tiene un tamaño de 172.025 registros, equivalentes al 73,1% de la población total.

2.3. Calidad de los datos:

Variable	Datos válidos	Datos faltantes / nulos	% de datos nulos
P6040	172.025	0	0
P1897	172.025	0	0

Variable	Min	Max
P6040	18	108
P1897	0	10

Observación: Ninguna de las variables necesarias para este estudio tiene datos faltantes o que requieran un tratamiento especial, pues todas las respuestas están dentro del rango esperado.

3. Análisis Descriptivo

3.1.Resumen descriptivo:

Para la variable P6040 (edad) se calcularon las principales medidas descriptivas. Para la variable P1897 (nivel de satisfacción con la salud, de 0 a 10) se calculó la distribución de frecuencias, dado que es una variable categórica ordinal con un número limitado de valores posibles.

Variable	Media	Mediana	Mínimo	Máximo
P6040 (Edad)	45,8	44	18	108

Nivel de satisfacción	Cantidad de personas	% del total
0	852	0,5
1	436	0,3
2	1.158	0,7
3	2.487	1,4
4	4.130	2,4
5	10.845	6,3
6	14.514	8,4
7	25.652	14,9
8	44.624	25,9
9	29.342	17,1
10	37.985	22,1

3.2.Relación que debe interpretarse con precaución:

Se observó que las personas mayores tienden a reportar niveles más bajos de satisfacción con su salud, mientras que las personas más jóvenes tienden a reportar niveles más altos. Sin embargo, esto no significa que la edad sea la causa de esa diferencia: puede que la verdadera razón sea otra variable no medida, como el estado de salud física o la situación laboral, que también cambian con la edad.

3.3.Valores atípicos:

La edad más alta que aparece en los datos es 108 años. No parece un error (no es un valor imposible como 300 o un número negativo), simplemente es un caso poco común. Por eso se considera un dato válido, una persona muy mayor pero real.

4. Hallazgos

Los resultados muestran que la satisfacción con la salud se concentra principalmente en valores altos. El 80 % de las personas adultas analizadas reportó niveles de satisfacción entre 7 y 10, y específicamente el 65,1 % se ubicó entre 8 y 10. El nivel más frecuente fue 8, con el 25,9 % de las respuestas. En contraste, únicamente el 5,3 % reportó valores entre 0 y 4. Esto indica que dentro de la muestra analizada predomina una percepción más positiva del estado de salud.

Al comparar la edad con el nivel de satisfacción también se observa que las personas de mayor edad suelen ya concentrarse en niveles de satisfacción más bajos, y que las personas más jóvenes aparecen con mas frecuencia en niveles altos. Este resultado permite responder la pregunta analítica planteada porque sugiere que existe una relación entre la edad y la satisfacción con la salud. Sin embargo, esta asociación no permite concluir que una mayor edad sea la causa de una menor satisfacción. Pueden existir otras características relacionadas tanto con la edad como con la percepción de salud por ejemplo el estado de salud física, la situación laboral, los ingresos u otras condiciones de vida.

5. Reflexión

¿Qué fue lo más difícil al momento de transformar una necesidad de información en una pregunta analítica?

La principal dificultad creo que fue pasar de una necesidad amplia como comprender el bienestar de la población, a una pregunta específica que pudiera responderse con las variables disponibles. Fue necesario decidir qué dimensión del bienestar estudiar y qué característica de la población utilizar para compararla. Finalmente seleccionamos la edad y la satisfacción con la salud porque permiten formular una relación cuantitativa concreta y medible. También fue importante asegurarnos de que la pregunta no intentara responder demasiados aspectos al mismo tiempo. Eso fue lo que permitió pasar de un problema general sobre el bienestar a una pregunta bien enfocada sobre la relación entre edad y satisfacción con la salud.

¿Qué decisiones tuvieron que tomar durante la selección y preparación de los datos y cómo influyeron estas decisiones en el análisis?

Primero seleccionamos P6040, que correspondía a la edad, y P1897 que correspondía al nivel de satisfacción con la salud, por ser las variables necesarias para responder la pregunta analítica. Después se decidió conservar únicamente a las personas de 18 años o más, obteniendo una muestra de 172.025 registros. Inicialmente exploramos P753S2 para realizar el filtro geográfico, pero se reducía la muestra a aproximadamente 253 observaciones. Siguiendo la aclaración del profesor, se decidió no aplicar el filtro y trabajar solamente con el criterio de edad. También evaluamos la calidad de las variables seleccionadas y se encontró que no presentaban valores faltantes y que sus valores estaban dentro de los rangos esperados. Por eso no fue necesario eliminar registros ni realizar imputaciones.

Estas decisiones permitieron conservar una muestra amplia para realizar el análisis descriptivo, pero también definieron el alcance de las conclusiones, los resultados permiten estudiar la relación entre edad y satisfacción con la salud dentro de la muestra adulta analizada, pero no establecer causalidad ni hacer afirmaciones exclusivamente sobre la población de Bogotá por los filtros dados.